

Rapport détaillé de la SAE S4.C.01

DÉVELOPPEMENT AVEC UNE BASE DE DONNÉES ET VISUALISATION

1 - Analyse des Datasets

Cette section présente l'analyse des trois jeux de données retenus pour le projet : OpenAQ, World Cities Database et World Bank Indicators. Pour chaque source, nous examinons la structure, la signification des champs clés, la qualité des données ainsi que les stratégies de jointure entre les sources.

1.1. OpenAQ – Global Air Quality Data

OpenAQ est une plateforme open source contenant les mesures de polluants issues de milliers de stations réparties dans le monde entier. Les données sont collectées en quasi-temps réel auprès de réseaux gouvernementaux et privés. Chaque enregistrement correspond à une mesure d'un polluant donné, effectuée à un instant précis par une station identifiée.

Ce dataset a nécessité le regroupement de plusieurs fichiers CSV téléchargés depuis la plateforme OpenAQ, chacun correspondant à une période ou une région différente. Un script Python a été utilisé pour fusionner l'ensemble en un fichier CSV unique, tout en dédoublant les enregistrements et en normalisant les en-têtes de colonnes.

Colonne	Type	Description
location_id	INTEGER	Identifiant unique de la station
city	VARCHAR	Ville de la station
country	CHAR(2)	Code pays ISO 2 lettres (ex : FR)
latitude / longitude	DECIMAL	Coordonnées GPS de la station
parameter	VARCHAR	Polluant mesuré : PM2.5, PM10, NO ₂ , CO, O ₃ , SO ₂
value	FLOAT	Valeur de concentration mesurée
unit	VARCHAR	Unité : µg/m ³ ou ppm
date_utc	TIMESTAMP	Date et heure de la mesure (UTC)

Les polluants couverts sont : les particules fines PM2.5 et PM10 (les plus nocives pour les voies respiratoires), le dioxyde d'azote NO₂ (issu principalement du trafic routier), le monoxyde de carbone CO, l'ozone O₃ et le dioxyde de soufre SO₂ (lié aux activités industrielles). Les seuils de l'OMS constituent la référence internationale pour évaluer la dangerosité de chaque polluant.

1.2. World Cities Database

DIALLO Djeneba
MEIMOUN Anton
OUADAH Yanis
BRAHIM Ilyes

Ce référentiel géographique recense environ 40 000 villes dans le monde, avec leurs caractéristiques démographiques et géographiques. Il joue le rôle de table pivot entre les

données OpenAQ et les indicateurs de la Banque mondiale, en fournissant le lien entre les codes ISO-2 (utilisés par OpenAQ) et ISO-3 (utilisés par le World Bank).

Ce jeu de données était fourni sous la forme d'un fichier CSV unique et complet, directement exploitable.

Colonne	Type	Description
city_ascii	VARCHAR	Nom de la ville sans accents — utilisé pour jointure avec OpenAQ
lat / lng	DECIMAL	Coordonnées GPS — jointure spatiale si nom de ville ambigu
iso2	CHAR(2)	Code pays 2 lettres — jointure avec OpenAQ (country)
iso3	CHAR(3)	Code pays 3 lettres — jointure avec World Bank
population	INTEGER	Population de la ville

1.3. World Bank Indicators

La Banque mondiale met à disposition des indicateurs socio-économiques et environnementaux par pays et par année. Ces données permettent de contextualiser les niveaux de pollution mesurés par OpenAQ avec des facteurs structurels tels que le taux d'urbanisation ou la consommation énergétique.

Les indicateurs de la Banque mondiale étaient répartis sur plusieurs fichiers CSV (un par indicateur ou par groupe d'années). Un script Python a permis de les fusionner en un seul fichier CSV structuré par pays et par année, en en retenant que les indicateurs effectivement renseignés dans notre d'analyse.

Colonne / Indicateur	Type	Description
country_code	CHAR(3)	Code ISO 3 lettres — jointure avec World Cities (iso3)
year	INTEGER	Année de l'observation
Urbanisation (SP.URB.TOTL.IN.ZS)	FLOAT	% de population urbaine
consommation_energie (EG.USE.PCAP.KG.OE)	FLOAT	Consommation d'énergie par habitant (kg équivalent pétrole)
deces_pollution_air (SH.STA.AIRP.P5)	FLOAT	Décès liés à la pollution de l'air pour 100 000 hab.

DIALLO Djeneba
MEIMOUN Anton
OUADAH Yanis
BRAHIM Ilyes

Deux indicateurs qui étaient envisagés le taux de motorisation (IS.VEH.PCAR.P3) et les émissions de CO₂ par habitant (EN.ATM.CO2E.PC) ont été finalement non exploitées car les données disponibles sur la période d'étude étaient insuffisantes ou absentes pour un nombre significatif de pays.

1.4. Liens entre les datasets

Les trois datasets se rejoignent via les codes pays ISO. World Cities joue le rôle de table pivot : son champ iso2 permet de rejoindre OpenAQ, et son champ iso3 permet de rejoindre World Bank.

Dataset A	Clé A	Dataset B	Clé B
OpenAQ	country (iso2)	World Cities	iso2
OpenAQ	city	World Cities	city_ascii
World Cities	iso3	World Bank	country_code

DIALLO Djeneba
MEIMOUN Anton
OUADAH Yanis
BRAHIM Ilyes

2 - Extraction et nettoyage des données

2.1. Extraction des données

Chaque source a été traitée différemment selon sa nature et son format de distribution :

World Cities Database

Ce jeu de données était disponible sous la forme d'un unique fichier CSV téléchargeable directement depuis le site simplemaps.com. Aucune opération de fusion n'a été nécessaire. Seules les colonnes utiles à notre modèle ont été conservées : city, city_ascii, lat, lng, iso2, iso3, population.

OpenAQ

Les données OpenAQ étaient distribuées en plusieurs fichiers CSV correspondant à différentes périodes temporelles et régions géographiques. Un script Python a été développé pour automatiser le regroupement de ces fichiers en un seul CSV homogène. Ce script réalise notamment la concaténation des fichiers, la normalisation des en-têtes de colonnes (mise en minuscules, suppression des espaces), et la déduplication des lignes strictement identiques.

World Bank Indicators

De manière similaire à OpenAQ, les indicateurs de la Banque mondiale étaient répartis sur plusieurs fichiers CSV, un par indicateur. Un second script Python a permis de fusionner ces fichiers en pivotant les données : chaque ligne du fichier résultant correspond à un pays et une année, avec une colonne par indicateur retenu. Les lignes pour lesquelles aucun indicateur n'était renseigné ont été écartées.

2.2. Nettoyage des données

Plusieurs opérations de nettoyage ont été appliquées sur les trois datasets afin de garantir l'intégrité des données insérées en base.

Suppression des doublons et des valeurs nulles

Des enregistrements en double ont été détectés dans les données OpenAQ, notamment pour des stations ayant transmis plusieurs fois la même mesure à la même date. Ces doublons ont été supprimés en conservant la première occurrence. Par ailleurs, les enregistrements présentant des valeurs nulles sur des champs critiques (identifiant de station, valeur de mesure, code polluant, date) ont été écartés, car ils ne permettent pas une intégration cohérente dans le schéma relationnel.

Filtrage des valeurs aberrantes

Des valeurs négatives ont été détectées dans le champ value des mesures OpenAQ. Ces valeurs sont physiquement impossibles pour une concentration de polluant et résultent soit d'erreurs de capteurs, soit d'artefacts d'instrumentation. Elles ont systématiquement été supprimées. De même, des valeurs extrêmement élevées, incohérentes avec les ordres de grandeur habituels pour les polluants concernés, ont été identifiées comme aberrantes et exclues de l'ensemble de données final.

DIALLO Djeneba
MEIMOUN Anton
OUADAH Yanis
BRAHIM Ilyes

Ces anomalies constituent d'ailleurs un matériau d'analyse pertinent pour la partie visualisation Qlik, qui se focalise précisément sur les sous-ensembles de données incohérents afin d'en proposer une explication contextuelle.

Normalisation et uniformisation

Les noms de villes ont fait l'objet d'une normalisation (conversion en minuscules, suppression des accents) afin d'améliorer la fiabilité des jointures entre OpenAQ et World Cities via le champ `city_ascii`. Les codes pays ont été vérifiés et harmonisés au format ISO-2 pour les jointures entre OpenAQ et World Cities, et au format ISO-3 pour les jointures entre World Cities et World Bank.

DIALLO Djeneba
MEIMOUN Anton
OUADAH Yanis
BRAHIM Ilyes

3 - Modélisation de la base de données relationnelle

Le modèle relationnel a été conçu pour représenter les entités métier dans la mesure de la qualité de l'air, en respectant les règles d'intégrité référentielle et les formes normales classiques.

3.1 Entités et attributs

Le schéma relationnel comporte six tables principales :

Table Pays

Représente les pays, identifiés par leur code ISO-2 (clé primaire). Les champs iso3 et nom_pays complètent l'identification du pays. Cette table sert de point d'ancrage pour la jointure avec les données World Bank.

Table Ville

Chaque ville est identifiée par un identifiant entier (ville_id). Elle est rattachée à un pays via une clé étrangère iso2. Les champs nom_ville, nom_ascii, latitude, longitude, population et region décrivent les caractéristiques géographiques et démographiques de la ville.

Table Station

Une station de mesure est rattachée à une ville (clé étrangère ville_id). Elle possède un nom, des coordonnées GPS propres (qui peuvent différer de celles de la ville) et un indicateur booléen est_mobile signalant si la station est fixe ou mobile.

Table Polluant

Identifiée par son code (clé primaire de type VARCHAR), cette table contient le nom complet du polluant, son unité de mesure et le seuil OMS de référence. Ce seuil permet d'évaluer la criticité d'une mesure donnée.

Table Mesure

Table centrale du modèle, elle enregistre chaque relevé de polluant : la valeur mesurée (FLOAT), la date et heure UTC (TIMESTAMP), la station productrice (clé étrangère station_id) et le polluant concerné (clé étrangère code).

Table indicateur_pays


Cette table stocke les indicateurs socio-économiques de la Banque mondiale par pays et par année. Elle est reliée à la table Pays via la clé étrangère iso2. Elle contient les champs taux_urbanisation, consommation_energie et deces_pollution_air.

3.2 Choix de modélisation


Les relations entre entités ont été définies comme suit : un pays possède plusieurs villes (1,n) ; une ville peut contenir plusieurs stations (0,n) ; une station produit plusieurs mesures (1,n) ; chaque mesure est associée à un polluant (1,1). Cette structuration respecte la troisième forme normale (3NF) et garantit l'absence de redondance dans les données. La hiérarchie géographique Pays → Ville → Station constitue l'axe d'organisation principal des données de mesure.

DIALLO Djeneba
MEIMOUN Anton
OUADAH Yanis
BRAHIM Ilyes

MCD :



MLD :



4. Modélisation de la base de données multidimensionnelle

Le modèle multidimensionnel a été conçu pour optimiser les analyses OLAP sur les données de qualité de l'air. Contrairement au modèle relationnel, optimisé pour l'intégrité des données, le modèle multidimensionnel accepte une certaine dénormalisation afin de réduire le nombre de jointures nécessaires aux requêtes analytiques.

4.1 Choix du schéma : constellation

Nous avons opté pour un schéma en constellation, comportant deux tables de faits partageant des dimensions communes. Ce choix est motivé par la différence de grain entre les deux sources de données :

- FAIT_MESURE_POLLUTION : grain horaire ou journalier, au niveau de la station et du polluant. Ce sont les mesures individuelles issues d'OpenAQ.
- FAIT_INDICATEUR_PAYS : grain annuel, au niveau du pays. Ce sont les indicateurs socio-économiques issus du World Bank.

Regrouper ces deux faits dans une même table aurait entraîné de nombreuses valeurs nulles et une violation du principe fondamental de cohérence de grain. La constellation permet au contraire d'analyser chaque fait de manière autonome, tout en autorisant des croisements analytiques via les dimensions partagées (notamment DIM_PAYS et DIM_TEMPS).

4.2 Tables de dimensions

DIM_TEMPS

Construite à partir du champ `date_utc` de la table `Mesure`, cette dimension décompose le timestamp en attributs séparés : année, mois, jour. Cette décomposition est indispensable pour permettre les opérations d'agrégation OLAP de type ROLLUP(année, mois, jour) sans recourir à des fonctions de date dans chaque requête.

DIM_POLLUANT

Reprend directement la table `Polluant` du modèle relationnel, avec l'ajout d'une clé de substitution entière (`id_polluant`). Le code, le nom complet et l'unité de mesure permettent de filtrer et regrouper les analyses par type de polluant.

DIM_PAYS

Dimension partagée par les deux tables de faits. Elle regroupe les informations descriptives du pays : identifiant, nom, codes ISO-2 et ISO-3. Elle constitue le point de jonction analytique entre les mesures de pollution et les indicateurs socio-économiques.

DIM_VILLE

Rattachée à DIM_PAYS via une clé étrangère, cette dimension conserve les informations démographiques et géographiques de la ville (nom, population, coordonnées). Le rattachement explicite à DIM_PAYS permet de naviguer dans la hiérarchie géographique Ville → Pays lors des analyses de type drill-up/drill-down.

DIALLO Djeneba
 MEIMOUN Anton
 OUADAH Yanis
 BRAHIM Ilyes
 DIM_STATION

Dimension décrivant les stations de mesure, rattachée à DIM_VILLE. Elle contient le nom de la station et sa clé étrangère vers DIM_VILLE, permettant de remonter la hiérarchie Station → Ville → Pays.

4.3 Tables de faits


FAIT_MESURE_POLLUTION

Table de faits principale. Elle contient les mesures numériques de polluants : la valeur brute, une valeur normalisée (ratio valeur / seuil OMS, facilitant les comparaisons inter-polluants) et un score de fiabilité. Elle référence les dimensions DIM_TEMPS, DIM_POLLUANT, DIM_STATION et DIM_PAYS (via DIM_VILLE et DIM_STATION).

FAIT_INDICATEUR_PAYS

Table de faits secondaire, au grain annuel par pays. Elle contient les indicateurs socio-économiques retenus (taux d'urbanisation, consommation d'énergie, décès liés à la pollution, taux de motorisation, émissions de CO₂, revenu national) et référence les dimensions DIM_TEMPS (à l'année) et DIM_PAYS. Elle partage ces deux dimensions avec FAIT_MESURE_POLLUTION, ce qui autorise des croisements analytiques entre les niveaux de pollution mesurés et le contexte socio-économique des pays.

4.4 Justification des choix de modélisation



DIALLO Djeneba
MEIMOUN Anton
OUADAH Yanis
BRAHIM Ilyes

Le choix du schéma en constellation plutôt qu'en étoile simple est justifié par trois arguments principaux :

- Les mesures horaires de polluants et les indicateurs annuels par pays n'ont pas le même niveau de granularité. Les regrouper dans une même table de faits conduirait à des agrégations incohérentes.
- La dénormalisation de la hiérarchie géographique (Station → Ville → Pays répartie sur trois dimensions liées) permet des jointures directes sans traverser la chaîne complète à chaque requête, tout en conservant la possibilité de navigation hiérarchique pour les opérations OLAP.
- La structure en constellation facilite l'ajout ultérieur de nouvelles tables de faits (données météorologiques, données de trafic) partageant les dimensions existantes, sans modifier le schéma en place.

La décomposition de `date_utc` en dimension `DIM_TEMPS` explicite est également un choix délibéré : elle permet d'utiliser les opérateurs OLAP `ROLLUP` et `CUBE` sur les niveaux temporels sans recourir à des fonctions d'extraction de date dans chaque requête, ce qui améliore significativement les performances sur de grands volumes de données.